

FIAP

Pós-Tech em Data Analytics

Alexandre de Souza Amorim – RM372077

Allison Lima – RM372648

Caio Rodrigues Bosnic Barbosa – RM372603

Gusthavo Lourenço Rios Soares – RM371911

Tech Challenge - Fase 3

Estrutura do Mercado Brasileiro de dados (2023-2025)

São Paulo

2026

SUMÁRIO

1. Introdução.....	3
1.1. Contexto do estudo.....	3
1.2. Objetivo.....	3
2. Arquitetura dos Dados.....	4
2.1. Fontes e estrutura dos dados.....	4
2.2. Processamento e arquitetura em camadas.....	4
2.3. Fluxo de dados na AWS.....	5
2.4. Decisões técnicas relevantes.....	5
3. Questões de Negócio.....	6
3.1. Como está estruturado o mercado brasileiro de Dados?.....	6
3.2. Quais perfis profissionais são mais valorizados pelo mercado?.....	6
3.3. Qual é o cenário de diversidade de gênero nas carreiras de dados?.....	7
3.4. Quais tecnologias apresentam mais adoção entre os profissionais?.....	7
3.5. Qual é o índice de adoção de IA e seu impacto?.....	8
3.6. Existem diferenças relevantes entre regiões, senioridades ou modelos de trabalho?... 8	
3.7. Quais oportunidades e desafios podem ser identificados para empresas que desejam investir em Dados e Inteligência Artificial?.....	9
4. Insights e Recomendações estratégicas.....	9
5. Limitações do estudo.....	10
6. Conclusão.....	11
7. Repositório do Projeto (GitHub).....	11
8. Referências.....	11

1. Introdução

1.1. Contexto do estudo

Com o aumento da geração de dados nos últimos anos, também cresceram as possibilidades de processamento e utilização dessas informações para gerar insights, solucionar problemas e apoiar diferentes processos de tomada de decisão. Esse avanço contribuiu para o desenvolvimento de um ecossistema cada vez mais amplo em torno dos dados e, conseqüentemente, para o crescimento do mercado de trabalho na área.

Esse mercado passou a reunir diferentes cargos, níveis de senioridade e especializações, com profissionais atuando em diferentes etapas do ciclo de dados, desde sua estruturação e processamento até análises descritivas e preditivas, desenvolvimento de modelos e geração de informações para apoio às decisões das organizações. Buscando compreender esse cenário profissional, desde 2021 é divulgada anualmente a pesquisa *State of Data Brazil*, realizada pela comunidade Data Hackers em parceria com a Bain. A pesquisa reúne informações sobre formação acadêmica, experiência profissional, características demográficas, remuneração, modelos de trabalho, desafios enfrentados pelos profissionais e outros aspectos relevantes para a compreensão do mercado brasileiro de Dados.

1.2. Objetivo

O trabalho tem como objetivo estruturar uma solução de Engenharia de Dados e Analytics, aplicando conceitos de Big Data e Analytics ao longo do ciclo de vida dos dados. Para isso, o projeto contempla a ingestão e organização das bases, estruturação dos dados em camadas, processamento, transformação, catalogação e realização de consultas analíticas em ambiente Cloud.

A partir dessa estrutura, são analisados os dados das pesquisas *State of Data Brazil* de 2023, 2024 e 2025, buscando compreender o mercado brasileiro de Dados, identificar padrões e tendências e gerar insights capazes de responder às questões de negócio propostas. A análise considera aspectos como perfil dos profissionais, formação, experiência, remuneração, senioridade, modelos de trabalho, tecnologias utilizadas e adoção de IA.

Salvo indicação em contrário, os percentuais apresentados neste relatório referem-se à edição 2025 da pesquisa. Quando um indicador é comparado entre as três edições, isso está dito na própria frase. Vários blocos do questionário são condicionais, respondidos apenas por

parte dos participantes, então cada indicador traz a base sobre a qual foi calculado sempre que ela difere do total de 14.002 respondentes.

2. Arquitetura dos Dados

2.1. Fontes e estrutura dos dados

As bases utilizadas correspondem às pesquisas *State of Data Brazil* de 2023, 2024 e 2025, disponibilizadas originalmente em formato CSV. Cada edição apresenta uma estrutura própria, com diferenças na quantidade de colunas (399 em 2023, 403 em 2024 e 388 em 2025), na nomenclatura e na organização das informações. Nenhuma das três traz uma coluna que identifique o ano da pesquisa, e a chave primária muda de nome entre as edições, o que exige tratamento nas etapas seguintes. As pesquisas reúnem dados sobre características demográficas e profissionais dos participantes, incluindo idade, gênero, formação, experiência, cargo, senioridade, remuneração, localização e modelo de trabalho.

Os arquivos foram carregados no Amazon S3, que funciona como o armazenamento central da solução. Na primeira etapa, os dados foram organizados na camada Bronze, mantendo uma cópia fiel das três bases originais e preservando as informações disponibilizadas pelas pesquisas para as etapas posteriores de processamento.

2.2. Processamento e arquitetura em camadas

A solução foi organizada em três camadas no Amazon S3: Bronze, Silver e Gold, permitindo separar os dados de acordo com seu nível de tratamento e finalidade.

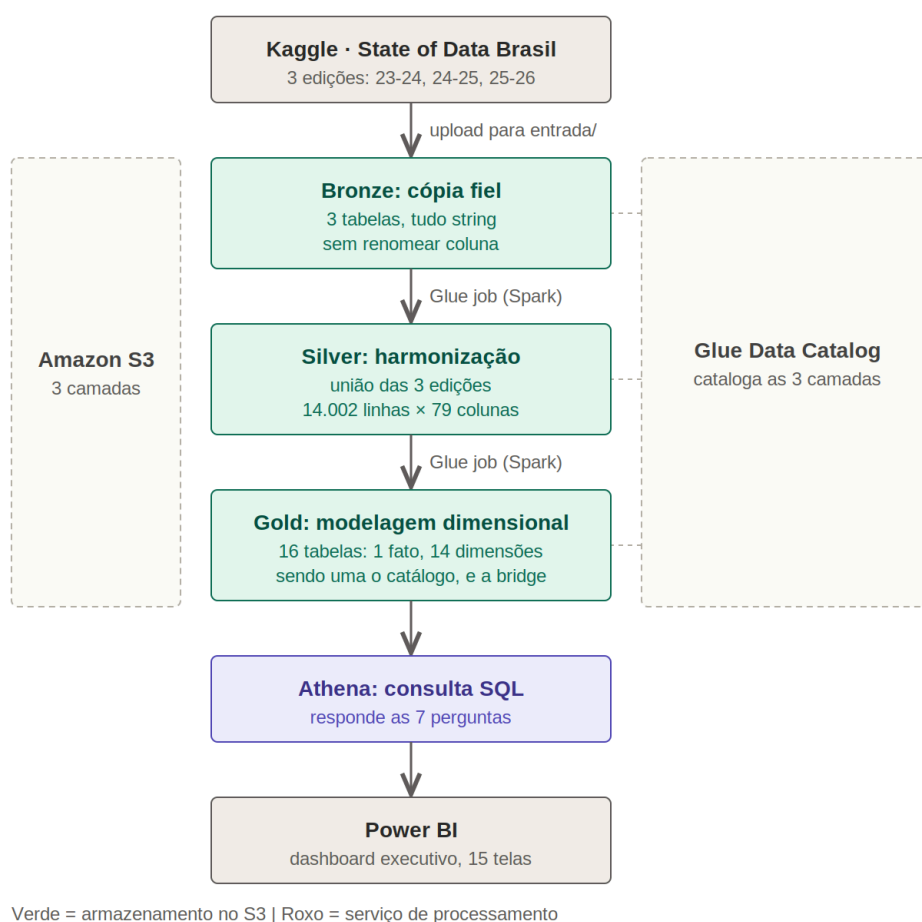
A Bronze mantém a cópia fiel das três edições da pesquisa. Na Silver, os dados passam pelo processo de harmonização das diferentes edições, permitindo unificar os três anos em uma única base, com a identificação do ano da pesquisa e uma estrutura comum para análise. O resultado dessa etapa possui 14.002 registros e 79 colunas, com os dados organizados e particionados por ano.

Na Gold, os dados são estruturados para consumo analítico por meio de um modelo dimensional com 16 tabelas: uma tabela fato no grão de respondente, 11 dimensões conformadas, um catálogo de opções, uma bridge que liga o fato às perguntas de múltipla escolha e duas tabelas desconectadas. Essa organização facilita as consultas utilizadas para responder às questões de negócio.

2.3. Fluxo de dados na AWS

O fluxo inicia com as três edições da pesquisa, carregadas em CSV no Amazon S3, formando a camada Bronze. A partir dela, o AWS Glue com Spark realiza a harmonização e gera a camada Silver. Em seguida, um segundo processamento do Glue transforma os dados em um modelo dimensional na camada Gold.

As três camadas são catalogadas pelo AWS Glue Data Catalog e consultadas pelo Amazon Athena, onde foram realizadas as análises SQL utilizadas para responder às sete questões de negócio. Os resultados são posteriormente utilizados no Power BI, em um dashboard executivo de 15 telas.



2.4. Decisões técnicas relevantes

Três características da base exigiram decisão explícita, porque todas produzem número errado sem gerar erro de execução. A primeira é a coluna de unidade federativa, que muda de significado entre as edições: em 2023 e 2024 registra onde o profissional mora e em

2025 onde ele nasceu, de modo que a camada Silver descarta essa coluna e deriva a sigla a partir do estado. A segunda é o denominador: blocos como o de estratégia de IA são respondidos apenas por gestores e o de maturidade de dados apenas por profissionais de engenharia, então calcular o percentual sobre os 14.002 respondentes inverteria a leitura. A terceira é o campo vazio nas perguntas de múltipla escolha, em que a ausência de resposta de quem não viu a pergunta precisa ser distinguida da ausência de marcação de quem viu e não selecionou a opção.

3. Questões de Negócio

3.1. Como está estruturado o mercado brasileiro de Dados?

O mercado brasileiro de Dados apresenta forte concentração no Sudeste, que reúne 64,4% dos profissionais em 2025, seguido por Sul (16,0%) e Nordeste (11,3%). Em relação aos setores, Finanças/Bancos (18,5%) e Tecnologia/Software (17,4%) concentram as maiores participações. Entre os cargos, destacam-se Analista de Dados (24,0%), Cientista de Dados (16,9%) e Engenheiro de Dados (16,1%).

A composição dos times reforça a importância dessas funções: Engenharia de Dados está presente em 66,4% dos times, Análise de Dados em 65,8% e Ciência de Dados em 55,9%. Funções mais especializadas apresentam menor presença, como Engenharia de ML/IA (35,4%) e Arquitetura de Dados (30,4%). O mercado também apresenta elevada qualificação formal, com 40,2% dos profissionais possuindo pós-graduação, 12,7% mestrado e 4,4% doutorado. Os dados indicam, portanto, um mercado concentrado em determinados setores e regiões, com funções de análise e engenharia já consolidadas e espaço para especializações mais avançadas em Dados e IA.

3.2. Quais perfis profissionais são mais valorizados pelo mercado?

A valorização dos profissionais de Dados pode ser observada por duas perspectivas: quanto o mercado paga e quanto o mercado disputa esses profissionais. Pelo primeiro aspecto, os maiores valores estão concentrados em funções mais especializadas. Nas três edições analisadas, Arquitetura de Dados apresenta remuneração média de aproximadamente R\$16,6 mil, enquanto Engenharia de ML/IA apresenta R\$15,9 mil e o maior P75, de R\$22,5 mil. Quando cargo e senioridade são combinados, Engenheiros de ML/IA Sênior recebem em média R\$20,2 mil, 72% acima de Analistas de Dados Sênior. Em 2025, a remuneração média passa de R\$4,2 mil no nível Júnior para R\$8,3 mil no Pleno, R\$14,3 mil no Sênior e R\$19,7

mil em Especialista/Staff+.

Pelo segundo aspecto, existe demanda e interesse por progressão, mas também um possível descompasso entre as oportunidades disponíveis e o perfil dos profissionais. Entre os 838 respondentes analisados em 2025, 53,0% identificam oportunidades de progressão e 51,6% consideram que possuem possibilidade de progressão rápida. Entretanto, apenas 35,8% afirmam encontrar vagas compatíveis com sua senioridade, enquanto 35,6% relatam receber muitas oportunidades. Os dados apontam que os perfis mais valorizados combinam senioridade e experiência com especializações de maior demanda, principalmente Machine Learning/IA, Arquitetura de Dados e Engenharia de Dados.

3.3. Qual é o cenário de diversidade de gênero nas carreiras de dados?

O mercado de Dados brasileiro ainda apresenta uma sub-representação feminina significativa. A participação das mulheres caiu de 24,4% em 2023 para 22,0% em 2025, enquanto a participação masculina passou de 75,1% para 77,5%. Além de a presença feminina continuar baixa, os dados indicam um retrocesso de 2,4 pontos percentuais no período.

Essa desigualdade também aparece na progressão de carreira, liderança e remuneração. Em 2025, as mulheres representam 37,6% dos profissionais Sêniores, contra 42,5% dos homens, e 19,1% ocupam posições de gestão, frente a 23,6% dos homens. No salário, o gap entre homens e mulheres no nível Sênior chega a 19%, equivalente a cerca de R\$2.826 por mês. Além disso, 61,9% das mulheres afirmam ter sido prejudicadas profissionalmente por sua identidade de gênero, contra 4,0% dos homens. O desafio da diversidade, portanto, envolve não apenas a entrada das mulheres no mercado, mas também sua permanência, crescimento profissional, acesso à liderança e remuneração.

3.4. Quais tecnologias apresentam mais adoção entre os profissionais?

Em 2025, Python (92,0%) e SQL (84,2%) apresentam as maiores taxas de adoção entre as linguagens. O R aparece com 15,6%, enquanto Scala (3,3%) e C/C++/C# (2,3%) apresentam participação bastante inferior.

Entre as tecnologias de Cloud, a AWS lidera com 48,3%, seguida por Azure (34,8%) e GCP (30,9%). No segmento de BI, o Power BI apresenta 59,0% de adoção, à frente do Looker (22,6%), Looker Studio (15,6%) e Tableau (13,6%). Já entre bancos e plataformas de dados, destacam-se PostgreSQL (36,8%), SQL Server (33,5%) e Databricks (32,9%). A

quantidade média de bancos e plataformas utilizados passou de 2,85 em 2023 para 3,45 em 2025, indicando maior diversificação do stack de dados. Considerando as três edições somadas, sobre os 9.007 respondentes do bloco, a ordem se inverte, com SQL em 89,5% e Python em 85,3%, o que indica que o Python assumiu a liderança na edição mais recente.

3.5. Qual é o índice de adoção de IA e seu impacto?

A adoção de Inteligência Artificial Generativa no mercado de Dados brasileiro já está praticamente consolidada entre os profissionais. O uso individual cresceu de 80,3% em 2023 para 93,5% em 2024 e 97,9% em 2025, mostrando que a IA passou a fazer parte do dia a dia de quem trabalha na área. Esse comportamento aparece em diferentes níveis de experiência, com adoção próxima de 90% entre Júnior, Pleno e Sênior.

O movimento mais interessante está nas empresas. Em 2025, 42,3% das empresas já pagavam pelo uso de IA, contra 6,4% em 2023 e 60,6% dos gestores consideravam a tecnologia uma prioridade alta. Ainda existe um gap de 37,3 pontos percentuais entre o uso pelos profissionais e a prioridade dada pelas empresas. Na prática, o desafio está cada vez menos na adoção da ferramenta e mais na capacidade das organizações de transformar esse uso em aplicações estruturadas e resultados para o negócio. Entre os principais obstáculos estão a falta de expertise (38,8%) e a dificuldade de compreender os casos de uso (32,0%), sobre os 587 gestores que responderam ao bloco em 2025.

3.6. Existem diferenças relevantes entre regiões, senioridades ou modelos de trabalho?

As diferenças entre regiões, senioridade e modelos de trabalho são relevantes, mas o modelo de trabalho apresenta um peso importante nos resultados. Em 2025, o Sudeste concentra 64,4% dos profissionais, com salário médio de R\$13.387, enquanto o Nordeste apresenta R\$10.224. A concentração regional também aparece na migração: 93,9% dos profissionais nascidos no Norte trabalham atualmente fora da região, assim como 83,0% dos nascidos no Nordeste.

O trabalho remoto ganha ainda mais importância conforme aumenta a senioridade. A diferença salarial chega a 18,6% entre Sêniores e 20,9% entre Especialistas/Staff+ em relação aos modelos presencial/híbrido. Na satisfação, o híbrido flexível apresenta 75,0% de profissionais satisfeitos e o remoto 74,5%, contra 54,0% no presencial. No cruzamento dos fatores, as cinco maiores médias salariais são de profissionais Sêniores em trabalho 100%

remoto, indicando que o modelo remoto pode ampliar oportunidades e reduzir o impacto das diferenças regionais

3.7. Quais oportunidades e desafios podem ser identificados para empresas que desejam investir em Dados e Inteligência Artificial?

Os dados mostram um mercado com boas oportunidades para empresas que desejam investir em Dados e IA, principalmente pela alta adoção das tecnologias entre os profissionais e pela crescente presença da IA nas estratégias corporativas. Ao mesmo tempo, existem desafios relacionados à disponibilidade de profissionais qualificados, à concentração regional do talento e à preparação da infraestrutura de dados.

Entre as principais oportunidades estão a ampliação do uso de IA, o acesso a talentos por meio de modelos de trabalho mais flexíveis e o desenvolvimento interno de profissionais. Já entre os desafios estão a falta de expertise, a definição de casos de uso, a preparação da infraestrutura e a retenção dos profissionais. Nesse cenário, o investimento depende não apenas da escolha das tecnologias, mas também da capacidade da empresa de criar um ambiente adequado para utilizá-las. Entre os obstáculos citados por gestores, os dois maiores são de capital humano e somam 71%, enquanto regulação, propriedade intelectual e ceticismo da alta direção somam menos de 27% juntos. Ao mesmo tempo, a participação de profissionais Júnior caiu de 29,7% para 22,3% ao longo das três edições, considerando apenas os níveis comparáveis entre elas, o que indica que a formação interna deixa de ser alternativa e passa a ser condição para sustentar a operação.

4. Insights e Recomendações estratégicas

A análise das três últimas edições da pesquisa permite identificar oportunidades e desafios que podem orientar empresas em suas decisões de investimento em Dados e IA:

- **Estruturar, não apenas incentivar o uso de IA:** com 97,9% dos profissionais já utilizando IA, o foco deve estar em governança, políticas de uso, segurança e casos de uso conectados ao negócio.
- **Tratar pessoas como parte central do investimento:** 71% das principais barreiras à IA estão relacionadas à falta de expertise e à dificuldade de identificar casos de uso. Investir apenas em ferramentas não é suficiente; capacitação e desenvolvimento precisam acompanhar a tecnologia.

- **Ampliar a busca por talentos fora do Sudeste:** embora 64,4% dos profissionais estejam concentrados no Sudeste, existe uma oportunidade de acessar talentos de outras regiões por meio do trabalho remoto.
- **Formar profissionais internamente:** a participação de Júniores vem diminuindo enquanto a de Sêniores aumenta. Como um Sênior custa, em média, 3,5 vezes mais que um Júnior, desenvolver profissionais internamente pode reduzir a dependência do mercado.
- **Avaliar a base de dados antes de iniciar projetos de IA:** 17,6% dos profissionais de engenharia de dados estão em empresas sem data lake, sobre a base de 2.396 que respondeu o bloco de maturidade. Antes de estabelecer cronogramas para projetos de IA, é importante verificar se a infraestrutura está preparada.
- **Competir por remuneração e flexibilidade:** remuneração (83,2%) e flexibilidade/remoto (56,6%) são os fatores mais citados pelos profissionais na escolha de uma oportunidade. Para atrair e reter talentos, esses aspectos devem receber atenção prioritária.

5. Limitações do estudo

A pesquisa *State of Data Brazil* é de participação voluntária, o que significa que descreve o perfil de quem responde a um levantamento da comunidade Data Hackers e não o mercado brasileiro de dados em sua totalidade. A base é adequada para comparar recortes dentro dela mesma e não para estimar totais do país.

A remuneração é declarada por faixa, então a média utilizada neste relatório é estimada pelo ponto médio de cada faixa. A comparação com o CAGED, registro administrativo oficial, mostra diferença de 2,4% no cargo de Engenheiro de Dados, o que sustenta o uso da estimativa, é de 16,6% no de Cientista de Dados, diferença explicada pela auto-seleção da amostra e pela presença de profissionais em regime de pessoa jurídica, que o CAGED não cobre.

Por fim, três colunas do questionário aceitam mais de uma marcação embora apresentem resposta única, entre elas linguagem preferida, nuvem preferida e ferramenta de BI de uso diário. Tratá-las como resposta única descartaria parte das respostas registradas.

6. Conclusão

O desenvolvimento deste projeto permitiu estruturar uma solução de Engenharia de Dados e Analytics em ambiente Cloud, utilizando as pesquisas *State of Data Brazil* de 2023, 2024 e 2025. A organização dos dados nas camadas Bronze, Silver e Gold, com processamento no AWS Glue, catalogação e consultas realizadas no Amazon Athena, possibilitou integrar as diferentes edições e transformá-las em uma base adequada para responder às sete questões de negócio. A análise revelou um mercado concentrado no Sudeste, com maior valorização de profissionais experientes e especializados, além de desafios relacionados à diversidade de gênero, senioridade e distribuição de talentos.

Entre os principais movimentos identificados, destaca-se a consolidação da IA Generativa, cujo uso chegou a 97,9% entre os profissionais em 2025, enquanto a estratégia corporativa ainda avança em ritmo menor. Também foram observadas mudanças no perfil tecnológico, no modelo de trabalho e na composição do mercado, reforçando a importância de profissionais qualificados, infraestrutura adequada e flexibilidade para atração e retenção de talentos. Os resultados mostram, portanto, que investir em Dados e IA envolve integrar dados, pessoas, infraestrutura e estratégia de negócio para transformar o avanço tecnológico em resultados para as organizações.

7. Repositório do Projeto (GitHub)

O repositório reúne os principais materiais do projeto: os scripts dos jobs do AWS Glue das camadas Bronze, Silver e Gold, os cinco notebooks que demonstram o pipeline da ingestão à geração dos gráficos, as consultas SQL executadas no Athena, o arquivo do dashboard em Power BI com o respectivo PDF, o material executivo em 25 slides, o diagrama editável da arquitetura e a documentação de apoio, com o contrato da camada Silver, o modelo dimensional, as validações e o registro das decisões técnicas. Ele também centraliza as informações necessárias para entender a arquitetura e reproduzir as etapas desenvolvidas. Repositório:

https://github.com/GusthavoSoares/tech_challenge_data_analytics_fase_3/tree/main

8. Referências

DATA HACKERS; BAIN & COMPANY. *State of Data Brazil*, edições 2023-2024, 2024-2025 e 2025-2026. Disponível em: <https://www.kaggle.com/datahackers/datasets>.

BAIN & COMPANY. Levantamento sobre prioridades estratégicas em Inteligência Artificial, maio de 2025. Aponta que 67% das organizações citam IA entre as cinco principais prioridades.

CETIC.BR. Pesquisa sobre o uso de tecnologias de informação e comunicação nas empresas brasileiras, 2025. Aponta que 17% das empresas com 10 ou mais funcionários e 50% das empresas com 250 ou mais utilizam Inteligência Artificial.

CAGED. Cadastro Geral de Empregados e Desempregados, julho de 2025 a junho de 2026. Base de 6.409 profissionais, utilizada para validar a estimativa salarial deste relatório.

BRASSCOM. Estudo sobre formação e demanda de profissionais de TI, abril de 2025. Aponta demanda de 665 mil profissionais em cinco anos contra 465 mil formados no período.

PEERS; MIT TECHNOLOGY REVIEW. Estudo sobre retorno de investimento em Inteligência Artificial Generativa, agosto de 2026. Aponta que 40,7% das empresas relatam retorno comprovado e que 72,7% dos bancos superaram o business case inicial.